

OPTIMASI MODEL MULTILAYER PERCEPTRON NEURAL NETWORK DALAM IDENTIFIKASI PENYAKIT JANTUNG MENGGUNAKAN PARTICLE SWARM OPTIMAZATION

OPTIMIZATION OF MULTILAYER PERCEPTRON NEURAL NETWORK MODEL FOR HEART DISEASE IDENTIFICATION USING PARTICLE SWARM OPTIMIZATION

Rizka Dwi Arzita^{1♥}, Syamsul Bahri², Muhammad Rijal Alfian³

¹ Jurusan Matematika, Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Mataram.
Jl. Majapahit 62 Mataram 83125, Nusa Tenggara Barat, Indonesia. Tel./Fax. 0370-663007,

♥email: rizkaarzita@gmail.com.

2

Abstrak. Penyakit jantung merupakan penyebab utama kematian mendadak di berbagai negara dan sering menyerang tanpa gejala yang jelas. Deteksi dini menjadi penting untuk mencegah risiko yang lebih fatal. Penelitian ini bertujuan membangun model identifikasi risiko penyakit jantung menggunakan *Multilayer Perceptron* (MLP) yang dioptimasi dengan *Particle Swarm Optimization* (PSO). PSO dipilih karena kemampuannya dalam mencari kombinasi *hyperparameter* terbaik yang berpengaruh langsung terhadap performa model MLP. Proses eksperimen dilakukan dengan mencoba beberapa konfigurasi parameter utama PSO, yaitu *swarm size* dan *maximum iteration*, guna memperoleh model dengan performa paling optimal. Hasil terbaik diperoleh pada kombinasi *swarm size* 10 dan *max iteration* 20, yang menghasilkan nilai *validation loss* terendah sebesar 0.1006. Model yang dihasilkan mampu mengidentifikasi penyakit jantung dengan akurasi, presisi, *recall*, dan *F1-score* masing-masing sebesar 99%, menunjukkan performa klasifikasi yang sangat baik. Penelitian ini menunjukkan bahwa pendekatan MLP-PSO mampu menghasilkan model identifikasi diterapkan sebagai sistem pendukung keputusan dalam bidang kesehatan, khususnya untuk identifikasi risiko penyakit jantung.

Kata kunci: penyakit jantung, optimasi *hyperparameter* model, *multilayer perceptron*, *particle swarm optimization*.

Abstract. Heart disease is a leading cause of sudden death in many countries and often occurs without clear symptoms. Early detection is crucial to prevent more fatal risks. This study aims to develop a heart disease risk identification model using a *Multilayer Perceptron* (MLP) optimized with *Particle Swarm Optimization* (PSO). PSO was chosen for its ability to find the best combination of hyperparameters, which directly affects the performance of the MLP model. The experiment was conducted by testing several configurations of the main PSO parameters, namely *swarm size* and *maximum iteration*, to obtain the most optimal model performance. The best result was achieved with a combination of *swarm size* 10 and *max iteration* 20, producing the lowest *validation loss* of 0.1006. The resulting model was able to identify heart disease with an accuracy, precision, recall, and *F1-score* of 99%, indicating excellent classification performance. This study demonstrates that the MLP-PSO approach can produce an identification model that is applicable as a decision support system in the healthcare sector, particularly for heart disease risk identification.

Key words: heart disease, *hyperparameter* model optimization, *multilayer perceptron*, *particle swarm optimization*.

PENDAHULUAN

Penyakit jantung merupakan salah satu gangguan serius pada sistem peredaran darah dan menjadi penyebab utama kematian di dunia. Data *World Health Organization* menunjukkan bahwa penyakit kardiovaskular, termasuk penyakit jantung, menyebabkan

sekitar 17,9 juta kematian setiap tahun [1]. Di Indonesia, jumlah kasus penyakit jantung mencapai 15,5 juta kasus pada tahun 2022, sehingga menempati posisi tertinggi dibandingkan penyakit berat lainnya [2]. Tingginya angka kasus dan kompleksitas dalam proses diagnosis membuat deteksi dini menjadi aspek yang sangat penting, namun analisis medis sering kali membutuhkan proses yang rumit dan memakan waktu [3].

Perkembangan teknologi *Artificial Intelligence* (AI) memberikan peluang besar dalam meningkatkan akurasi dan efisiensi diagnosis. Salah satu teknik AI yang banyak digunakan dalam analisis data medis adalah *Artificial Neural Network* (ANN), terutama karena kemampuannya dalam mempelajari pola non-linear yang kompleks [4]. Dari berbagai arsitektur ANN, *Multi-Layer Perceptron* (MLP) merupakan model yang umum diterapkan pada data tabular medis seperti data pasien, karena mampu mengenali interaksi antar variabel secara otomatis [5]. Beberapa penelitian menunjukkan bahwa MLP efektif dalam klasifikasi penyakit seperti diabetes, kanker, dan penyakit metabolik lainnya dengan akurasi yang cukup tinggi [6][7].

Namun demikian, performa MLP sangat dipengaruhi oleh pemilihan *hyperparameter*, seperti *learning rate*, jumlah *hidden layer*, jumlah neuron dalam setiap lapisan, dan *dropout rate* [8]. Proses penentuan *hyperparameter* tersebut biasanya dilakukan secara manual atau *trial-and-error*, sehingga kurang efisien dan tidak menjamin hasil optimal. Untuk mengatasi masalah ini, beberapa penelitian memanfaatkan teknik optimasi berbasis populasi, salah satunya *Particle Swarm Optimization* (PSO), yang terinspirasi oleh perilaku kawanan burung dalam mencari posisi terbaik [9].

PSO terbukti mampu menjelajahi ruang pencarian secara lebih efektif dan menemukan kombinasi *hyperparameter* yang optimal dalam berbagai penelitian, seperti prediksi IPK [10], prediksi harga telur ayam Ras [11], serta prediksi penjualan ponsel pintar [12]. Meskipun penerapan PSO dan MLP telah banyak digunakan pada berbagai bidang, penggunaan pendekatan PSO-MLP untuk identifikasi penyakit jantung masih jarang dilakukan, padahal penyakit ini merupakan penyebab kematian utama di Indonesia maupun dunia. Oleh karena itu, penelitian ini bertujuan untuk membangun model identifikasi penyakit jantung berbasis MLP yang dioptimasi menggunakan PSO,

sehingga mampu meningkatkan akurasi diagnosis dan memberikan dukungan pengambilan keputusan bagi tenaga medis secara lebih efektif dan efisien [13][14][15].

MATERI DAN METODE

Data yang digunakan merupakan data sekunder mengenai penyakit jantung yang tersedia pada repositori dataset UCI *Machine Learning Repository* dengan nama file *Heart Disease*. Dalam dataset ini, total dataset ada 1000 data dan 14 variabel, terdiri dari 13 variabel input yang mendeskripsikan karakteristik dari penyakit jantung dan 1 variabel target berupa label penyakit jantung. Adapun tahapan dalam penelitian ini sebagai berikut:

Data Prep-processing

Dataset tersebut kemudian dilakukan pre-processing yang mencakup pengecekan *missing value*, normalisasi menggunakan *MinMaxScaler*, serta pengacakan data (*shuffle*). Output dari proses ini adalah:

Tabel 1. Data setelah Tahap Preprocessing

age	sex	cp	trestbps	chol	f b s	rest ecg	tha lach	exang	old peak	slope	ca	thal	tar get
0,5	1	0,0	0,3	0,2	0	0,5	0,7	0	0,2	1,0	0,5	1,0	0
0,5	1	0,0	0,4	0,2	1	0,0	0,6	1	0,5	0,0	0,0	1,0	0
0,9	1	0,0	0,5	0,1	0	0,5	0,4	1	0,4	0,0	0,0	1,0	0
0,7	1	0,0	0,5	0,2	0	0,5	0,7	0	0,0	1,0	0,3	1,0	0
0,7	0	0,0	0,4	0,4	1	0,5	0,3	0	0,3	0,5	0,8	0,7	0
...
0,6	1	0,3	0,4	0,2	0	0,5	0,7	1	0,0	1,0	0,0	0,7	1
0,6	1	0,0	0,3	0,3	0	0,0	0,5	1	0,5	0,5	0,3	1,0	...
0,4	1	0,0	0,2	0,3	0	0,0	0,4	1	0,2	0,5	0,3	0,7	0
0,4	0	0,0	0,2	0,3	0	0,0	0,7	0	0,0	1,0	0,0	0,7	1
0,5	1	0,0	0,2	0,1	0	0,5	0,3	0	0,2	0,5	0,3	1,0	0

Pembagian Data

Selanjutnya, data dibagi menjadi tiga rasio pelatihan dan pengujian, yaitu 70:30, 80:20, dan 90:10, guna mengamati pengaruh rasio tersebut terhadap performa model.

Implementasi PSO dan MLP

Tahap berikutnya adalah implementasi PSO dalam mencari nilai *hyperparameter* untuk membangun model MLP. PSO digunakan untuk mencari kombinasi terbaik dari empat *hyperparameter* utama, yaitu *learning rate*, jumlah *hidden layer*, jumlah neuron

pada *hidden layer*, dan *dropout rate*. Rentang nilai pencariannya ditampilkan pada Tabel 2 berikut:

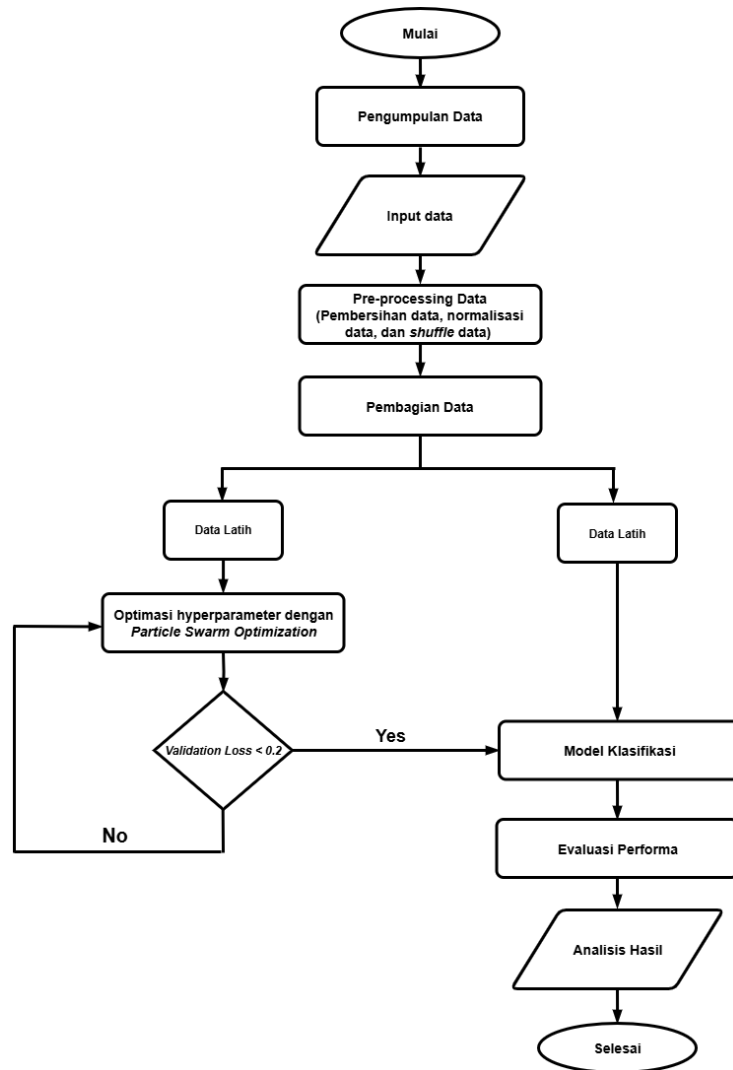
Tabel 2. Rentang nilai *hyperparameter* yang dioptimasi

<i>Hyperparameter</i>	Batas bawah (<i>lower bound</i>)	Batas atas (<i>upper bound</i>)
<i>Learning rate</i>	0,00001	0,1
Jumlah <i>hidden layer</i>	1	3
Jumlah neuron pada <i>hidden layer</i>	16	256
<i>Dropout rate</i>	0.2	0.5

Setiap kombinasi nilai direpresentasikan sebagai partikel dalam populasi PSO, dan nilai *validation loss* dijadikan fungsi objektif untuk dioptimalkan. Model MLP dibangun dengan arsitektur tiga lapisan, menggunakan fungsi aktivasi ReLU untuk *hidden layer* dan sigmoid untuk *output layer*. Proses pelatihan dilakukan dengan metode *backpropagation* dan optimasi bobot oleh algoritma Adam. Pergerakan partikel PSO dikendalikan oleh parameter *inertia weight* (w), *cognitive* (c_1), dan *social coefficient* (c_2). Setelah sejumlah iterasi, algoritma menghasilkan kombinasi *hyperparameter* terbaik dengan meminimalkan *validation loss* hingga ≤ 0.2 .

Evaluasi Performa Model

Model hasil optimasi tersebut dievaluasi menggunakan data pengujian melalui metrik *confusion matrix* yang mencakup akurasi, presisi, *recall*, dan F1-score untuk menilai kinerja klasifikasi. Akhirnya, dilakukan analisis terhadap performa model untuk melihat efektivitas PSO dalam meningkatkan kinerja MLP dalam identifikasi penyakit jantung. Berikut tahapan dalam penelitian disajikan pada Gambar 1:

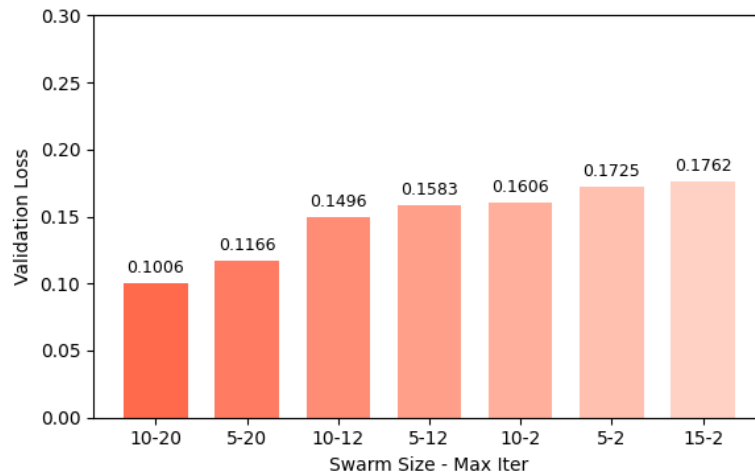


Gambar 1. Prosedur Penelitian

HASIL DAN DISKUSI

Hasil

Sebelum membangun model, dilakukan proses menemukan nilai *hyperparameter* terbaik menggunakan *Particle Swarm Optimization* (PSO). Dalam hal ini, PSO membentuk populasi partikel di mana setiap partikel merepresentasikan satu kombinasi *hyperparameter*. Kinerja tiap kombinasi dinilai berdasarkan nilai *validation loss*. Percobaan dilakukan pada kombinasi jumlah partikel (*swarmsize*) dan iterasi maksimum (*maxiter*) untuk mencari konfigurasi terbaik. Hasil pengujian ini ditunjukkan pada Gambar 2.



Gambar 2. Hasil uji coba *swarmsize* dan *maxiter* berdasarkan nilai *validation loss*

Kombinasi terbaik diperoleh pada *swarmsize* = 10 dan *maxiter* = 20 dengan nilai *validation loss* sebesar 0.1006. *Hyperparameter* optimal hasil dari proses PSO ditampilkan pada Tabel 3.

Tabel 3. Optimal *hyperparameter* dengan PSO

Optimal Hyperparameter	Nilai
<i>Learning rate</i>	: 0.00199
Jumlah <i>hidden layer</i>	: 3
Jumlah neuron pada <i>hidden layer</i>	: 113
<i>Dropout rate</i>	: 0.26
<i>Validation loss</i>	: 0.1006

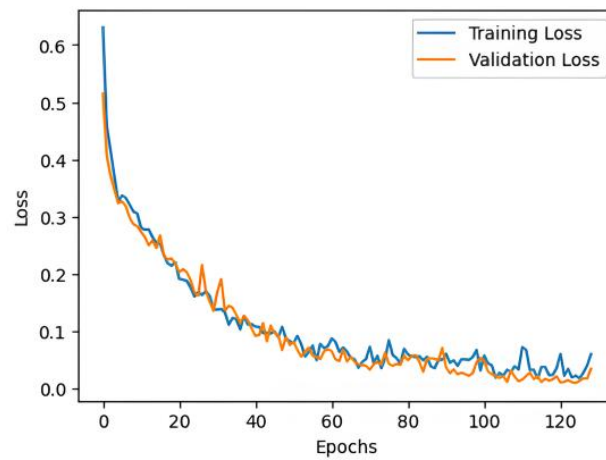
Model MLP kemudian dibangun berdasarkan kombinasi *hyperparameter* tersebut, dengan arsitektur sebagai berikut:

- Lapisan input: 13 neuron sesuai jumlah fitur.
- Tiga *hidden layer*: masing-masing 113 neuron, fungsi aktivasi ReLU, dan dropout 0.26.
- Lapisan output: 1 neuron, fungsi aktivasi sigmoid.

Model dilatih menggunakan optimizer ADAM, fungsi loss *binary crossentropy*, dengan pengaturan, 200 epoch, *batch size* 50, dan *early stopping*. Hasil pelatihan menunjukkan akurasi sebesar 99% pada data uji.

Rasio pembagian data yang digunakan adalah 70:30, yang berarti 70% data digunakan untuk pelatihan dan 30% untuk pengujian. Rasio ini dipilih karena memberikan hasil paling seimbang antara jumlah data yang cukup untuk melatih model dan cukup untuk menguji generalisasi model terhadap data yang belum pernah dilihat. Selain itu, hasil uji coba menunjukkan bahwa konfigurasi 70:30 menghasilkan

penurunan *loss* yang signifikan dan minim fluktuasi dibandingkan dengan model B dan model C, serta performa klasifikasi yang konsisten dan stabil.

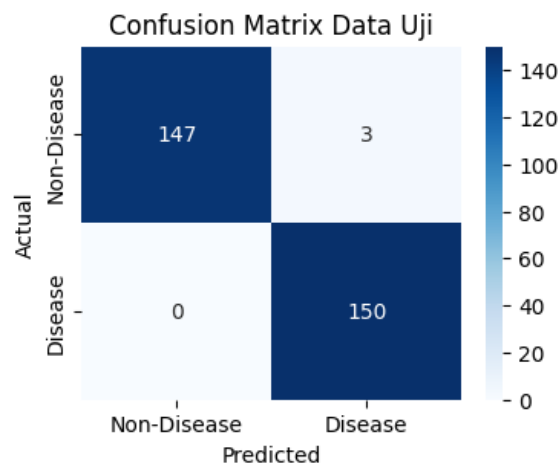


Gambar 3. Grafik penurunan *loss* pada data latih (*training*) dan data uji (*validation*) di model A

Selanjutnya, untuk membandingkan performa masing-masing konfigurasi, hasil pengujian model ditunjukkan dalam Tabel 4.

Rasio Split Data	Confusion Matrix	Accuracy	Precision	Recall	F1-Score
70:30	[[147 3] [0 150]]	99,00%	98,04%	100,00%	99,01%
80:20	[[109 3] [0 88]]	98,50%	96,70%	100,00%	98,32%
90:10	[[53 2] [0 45]]	98,00%	95,74%	100,00%	97,83%

Evaluasi terhadap hasil prediksi model ditunjukkan dalam bentuk *confusion matrix* (Gambar 3), yang menggambarkan distribusi hasil klasifikasi terhadap dua kelas: Non-Disease dan Disease.



Gambar 4. *Confusion Matrix* pada data uji untuk Model A

Berdasarkan Gambar 3, dari 300 data uji yang digunakan, model berhasil mengklasifikasikan 150 pasien non-penyakit jantung secara benar (*True Negative*) dan 147 pasien dengan risiko penyakit jantung secara tepat (*True Positive*). Hanya terjadi 3 kesalahan klasifikasi, yaitu 3 pasien sehat diklasifikasikan sebagai *Disease* (*False Positive*) dan tidak ada pasien *Disease* yang terklasifikasi sebagai sehat (*False Negative*). Hasil ini mencerminkan performa model yang sangat baik dalam membedakan kedua kelas, dengan presisi dan *recall* tinggi, serta kesalahan yang sangat minim.

Dari model yang telah dibangun kemudian disimpan dalam format “keras” untuk diimplementasikan dalam aplikasi prediksi berbasis model ini yang dibuat menggunakan Streamlit, sebagaimana ditunjukkan pada Gambar 4.

Deteksi Dini Penyakit Jantung

Masukkan data pasien untuk prediksi risiko penyakit jantung:

Usia	Kolesterol (mg/dL)	Angina Induksi Olahraga?
50 - +	200 - +	Tidak
Jenis Kelamin	Gula Darah Puasa > 120 mg/dl?	Depresi ST (Oldpeak)
Laki-laki	Tidak	1.00
Tipe Nyeri Dada	Hasil EKG Istirahat	-2.00 6.50
Tidak Nyeri	0	Kemiringan ST
Tekanan Darah Istirahat (mmHg)	Detak Jantung Maksimum	Menanjak
120 - +	150 - +	Jumlah Pembuluh Darah yang Utama (0-3)
		0
		Hasil Tes Thaliun (Thalassemia)
		Normal

Prediksi

Gambar 5. Aplikasi Prediksi Penyakit Jantung

Diskusi

Optimasi *hyperparameter* menggunakan PSO berhasil memberikan performa model MLP yang baik dalam mengidentifikasi penyakit jantung. Penggunaan PSO membantu mempercepat proses pencarian kombinasi *hyperparameter* terbaik tanpa perlu bergantung pada metode *trial-and-error* manual yang seringkali tidak efisien. Hasil ini sejalan dengan pendapat [16] yang menyatakan bahwa PSO dengan iterasi

yang lebih banyak daripada jumlah partikel cenderung memberikan hasil yang lebih stabil dalam menemukan solusi optimal. Selain itu, konfigurasi PSO yang ditetapkan dalam penelitian ini adalah $w = 0.5$, $c_1 = 1$, $c_2 = 1$ (Ariyanti *et al.*, 2023), di mana *inertia weight* dan koefisien kognitif-sosial yang seimbang dapat menjaga keseimbangan eksplorasi dan eksploitasi solusi.

Rasio pembagian data sebesar 70:30 juga terbukti memberikan hasil paling stabil dibandingkan dengan rasio lainnya. Hal ini menunjukkan bahwa rasio tersebut memberikan cukup data untuk proses pelatihan, sekaligus menyisakan porsi data yang memadai untuk menguji generalisasi model. Ketepatan ini tercermin dari hasil *confusion matrix* (Gambar 3) yang menunjukkan kesalahan prediksi sangat minim. Kinerja model juga diatur oleh pemilihan arsitektur jaringan yang proporsional dan penggunaan fungsi aktivasi serta dropout yang sesuai untuk menghindari *overfitting*. Secara teori, ini menguatkan prinsip bahwa kualitas data dan konfigurasi arsitektur memiliki peran besar dalam menentukan keberhasilan model MLP.

Dalam penelitian ini, memiliki kelebihan yaitu keberhasilan dalam memberikan akurasi prediksi yang tinggi dengan mengombinasikan metode PSO dan MLP, sekaligus menyederhanakan proses pemilihan *hyperparameter*. Selain itu, model yang dibangun juga memiliki arsitektur yang relatif ringan dan dapat diimplementasikan dalam aplikasi praktis yang ramah pengguna. Namun demikian, terdapat beberapa keterbatasan dalam penelitian ini, adalah waktu komputasi yang cenderung meningkat seiring dengan bertambahnya partikel dan iterasi dalam proses PSO. Selain itu, data yang digunakan berasal dari sumber terbuka (*UCI Repository*), bukan dari data klinis aktual di rumah sakit, sehingga masih diperlukan pengujian lebih lanjut untuk memastikan keandalan model di dunia nyata.

Hasil yang diperoleh dalam penelitian ini menunjukkan bahwa metode PSO mampu memberikan performa model MLP yang baik dalam mengidentifikasi penyakit jantung. Implementasi model dalam bentuk aplikasi prediksi juga menjadi nilai tambah, karena dapat dimanfaatkan sebagai alat bantu dalam proses deteksi dini risiko penyakit jantung.

KESIMPULAN

Dalam penelitian mengenai optimasi model *multilayer perceptron* untuk identifikasi penyakit jantung dengan *particle swarm optimization* ini, dapat disimpulkan bahwa model yang dibangun dengan konfigurasi awal PSO, yaitu *swarmsize* sebesar 10, *maxiter* sebanyak 20, *dimension* = 4, $w = 0.5$, $c_1 = 1$, dan $c_2 = 1$ diperoleh nilai *hyperparameter* terbaik dengan *learning rate* sebesar 0.00199, jumlah *hidden layer* ada 2, jumlah neuron di *hidden layer* sebesar 113 neuron, serta nilai *dropout rate* sebesar 0.26. Pemilihan konfigurasi awal tersebut menghasilkan nilai *validation loss* terendah sebesar 0.1006, yaitu terbukti dengan beberapa percobaan yang telah dilakukan. Dengan menggunakan nilai *hyperparameter* tersebut, model menunjukkan kinerja yang sangat baik, dengan *accuracy*, *precision*, *recall*, dan *F1-Score* masing-masing mencapai 99%. Artinya, model mampu melakukan identifikasi penyakit jantung dengan tepat

UCAPAN TERIMA KASIH

Dengan penuh rasa syukur, peneliti mengucapkan terima kasih kepada dosen pembimbing yang telah mendukung dan memberikan bimbingan sehingga penelitian ini dapat terselesaikan.

DAFTAR PUSTAKA

- [1] Cdc. (2021). Coronary Artery Disease. <https://www.cdc.gov/heart-disease/about/coronary-artery-disease.html>
- [2] Riset Kesehatan Dasar (Riskesdas). (2018). Badan Penelitian dan Pengembangan Kesehatan Kementerian RI tahun 2018.
- [3] Wahidin, A. J., Setiawan, A. E., & Bintoro, P. (2024). Machine Learning Untuk Klasifikasi Penyakit Jantung. *Aisyah Journal Of Informatics and Electrical Engineering (AJIEE)*, 6(1), 145-150.
- [4] Pradana, D., Luthfi Alghifari, M., Farhan Juna, M., & Palaguna, D. (2022). Klasifikasi Penyakit Jantung Menggunakan Metode Artificial Neural Network. *Indonesian Journal of Data and Science*, 3(2), 55-60. <https://doi.org/10.56705/ijodas.v3i2.35>.
- [5] Jiang, X., & Xu, C. (2022). Deep learning and machine learning with grid search to predict later occurrence of breast cancer metastasis using clinical data. *Journal of clinical medicine*, 11(19), 5772. <https://doi.org/10.3390/jcm11195772>
- [6] Sugandhi, Y. P., Warsito, B., & Hakim, A. R. (2019). Prediksi Harga Saham Harian Menggunakan Cascade Forward Neural Network (CFNN) Dengan Particle Swarm Optimization (PSO). *STATISTIKA Journal of Theoretical Statistics and Its Applications*, 19(2), 71-82. <https://doi.org/10.29313/jstat.v19i2.4878>.

- [7] Sari, N. R., & Mar'atullatifah, Y. (2023). Penerapan Multilayer Perceptron untuk Identifikasi Kanker Payudara. *Jurnal Cakrawala Ilmiah*, 2(8), 3261-3268.
- [8] Rochmawati, N., Hidayati, H. B., Yamasari, Y., Tjahyaningtjas, H. P. A., Yustanti, W., & Prihanto, A. (2021). Analisa Learning Rate dan Batch Size pada Klasifikasi Covid Menggunakan Deep Learning dengan Optimizer Adam. *JIEET (Journal of Information Engineering and Educational Technology)*, 5(2), 44-48. <https://doi.org/10.26740/jieet.v5n2.p44-48>.
- [9] Adrian, R., Fauziyyah, A. K., & Alam, S. (2022). Continuous Integration/Continuous Delivery Optimization on Network Automation using Gray Wolf Optimizer. *Sistemasi: Jurnal Sistem Informasi*, 11(3), 776-784. <https://doi.org/10.32520/stmsi.v11i3.2322>
- [10] Haq, M. Z. (2023). Prediksi Indeks Prestasi Kumulatif Mahasiswa berdasarkan Nem dengan Menggunakan Algoritma Neural Network Berbasis Particle Swarm Optimization. *Jurnal Kolaboratif Sains*, 6(2), 147-153.
- [11] Sylviani, N., & Soebroto, A. A. (2018). Peramalan Harga Pasar Telur Ayam Ras di Kota Malang dengan Menggunakan Metode" PSO-NN". *Jurnal Pengembangan Teknologi Informasi dan Ilmu Komputer*, 2(12), 6737-6745.
- [12] Rahmat, W. M., Hidayat, N., & Soebroto, A. A. (2023). Prediksi Penjualan Ponsel Pintar menggunakan Metode Jaringan Syaraf Tiruan Backpropagation Kombinasi Particle Swarm Optimization. *Jurnal Pengembangan Teknologi Informasi Dan Ilmu Komputer*, 7(1), 439-445. Diambil dari <https://j-ptiik.ub.ac.id/index.php/j-ptiik/article/view/12213>
- [13] Guntoro, I., Midyanti, D. M., & Hidayati, R. (2022). Penerapan dropout pada jaringan saraf tiruan backpropagation dalam mengklasifikasi tingkat fine fuel moisture code (FFMC) untuk kebakaran hutan dan lahan. *Coding Jurnal Komputer dan Aplikasi*, 10(01), 114-123. <https://doi.org/10.26418/coding.v10i01.52734>.
- [14] Putra, R. M., & Anjar Rani, N. (2020). Prediksi Curah Hujan Harian di Stasiun Meteorologi Kemayoran Menggunakan Artificial Neural Network (ANN). *Buletin GAW Bariri (BGB)*, 1(2), 101-108. <https://doi.org/10.31172/bgb.v1i2.35>.
- [15] Li, Z., Liu, F., Yang, W., Peng, S., & Zhou, J. (2021). A survey of convolutional neural networks: analysis, applications, and prospects. *IEEE transactions on neural networks and learning systems*, 33(12), 6999-7019. <https://doi.org/10.1109/TNNLS.2021.3084827>.
- [16] Ratnaweera, A., Halgamuge, S. K., & Watson, H. C. (2002). Particle swarm optimisation with time varying acceleration coefficients. In *Proceedings of the international conference on soft computing and intelligent systems* (pp. 240-255). <https://doi.org/10.1109/TEVC.2004.826071>.